

Imputing missing values in categorical datasets using EM & DA

郭奕 钟艳泓 郭镇涛

中国人民大学统计学院

2024 年 12 月 26 日

Overview

1. Introduction
2. Imputation for Missing Data Using EM
3. Multiply Imputation For Missing Data Using FRM & DA
4. Rpackage
5. References



1. Introduction

2. Imputation for Missing Data Using EM

3. Multiply Imputation For Missing Data Using FIRM & DA

4. Rpackage

5. References



Introduction I

本次汇报我们主要考虑分类变量数据缺失问题的插补，主要采用两种建模方法，分别是针对分类变量集所有可能情况的建模和仅对已有的数据集进行建模。下图展示了此类数据集的示意图，其中 n 行表示观测单元， p 列表示为这些单元记录的分类变量，缺失值用? 表示.

Introduction II




图: Multivariate dataset with missing values

1. Introduction

2. Imputation for Missing Data Using EM

3. Multiply Imputation For Missing Data Using FIRM & DA

4. Rpackage

5. References



First Modelling Method I

第一种建模方法是由 J.L.Schafer 在 1997 年的专著中提出。

设 $Y_1, \dots, Y_p$ 是一组分类变量，为了方便标记，我们假设每个分类变量的取值都为正整数，即

Y_j takes possible values $1, 2, \dots, d_j$, for $j = 1, 2, \dots, p$

这里，我们考虑 $1, 2, \dots, d_j$ 是无序的分类变量取值（即因子水平）。

对于上面的模型，所有可能的完整数据集可以被视作一个 $D \times p$ 的数据矩阵 Y ，且每个可能的样本都是独立的。我们可以将矩阵 Y “降维”成 D 个单元格的数组的集合，其中 $D = \prod_{j=1}^p d_j$ ，是分类变量不同因子水平的组合。实际上，在逻辑约束下，有些组合显然是不可能的，这样的单元格被称为结构零点，在本文中我们暂不考虑结构零点。

First Modelling Method II

记 x_d 表示落入单元格 $d(d = 1, 2, \dots, D)$ 的样本数量, 并记

$$\mathbf{x} = (x_1, \dots, x_D)$$

为所有单元格的频数或计数集。如果所有样本是独立的且样本数量和 $n = \sum_{d=1}^D x_d$ 是固定的, 则 $\mathbf{x}$ 服从多项分布, 写作

$$\mathbf{x}|\boldsymbol{\theta} \sim \text{Multi}(n, \boldsymbol{\theta}). \quad (1)$$

其中 $\boldsymbol{\theta} = (\theta_1, \dots, \theta_D)$. θ_d 就代表一个样本落入单元格 d 的概率。 $\mathbf{x}$ 的概率分布就写作

First Modelling Method III

$$P(\mathbf{x}|\boldsymbol{\theta}) = \frac{n!}{x_1!x_2!\cdots x_D!} \theta_1^{x_1} \theta_2^{x_2} \cdots \theta_D^{x_D}, \quad (2)$$

由于 n 是固定的，所以 (2) 可以看作是 $(x_1, \dots, x_{D-1})$ 的概率分布，同理 $\sum_{d=1}^D \theta_d = 1$ ，所以参数空间

$$\Theta = \{\boldsymbol{\theta} : \theta_d \geq 0 \text{ for all } d \text{ and } \sum_{d=1}^D \theta_d = 1\}$$

是一个 $D-1$ 维的单形。本文中我们允许 $\boldsymbol{\theta}$ 落在单形 Θ 的任何位置，这样的多项式模型也被称为是饱和的。

First Modelling Method IV

多项分布的似然函数可以写为

$$L(\boldsymbol{\theta}|\mathbf{x}) \propto \prod_{d=1}^D \theta_d^{x_d} l_{\Theta}(\theta), \quad (3)$$

其中 $l_{\Theta}(\theta)$ 是示性函数。则 θ_d 的极大似然估计为

$$\hat{\theta}_d = \frac{x_d}{n}, d = 1, \dots, D. \quad (4)$$

First Modelling Method V

运用贝叶斯推断最简单的方式是对多项式模型假设一个 Dirichlet 先验分布，通常假定 θ 服从参数为 $\alpha = (\alpha_1, \dots, \alpha_D)$ 的 Dirichlet 分布。

$$\text{Diri}(\theta|\alpha) = \frac{\Gamma(\sum_i \alpha_d)}{\prod_d \Gamma(\alpha_d)} \prod_{d=1}^D \theta_d^{\alpha_d-1}. \quad (5)$$

当 Dirichlet 分布作为先验分布的时候，我们很自然地只考虑它的核，即

$$\pi(\theta) \propto \prod_{d=1}^D \theta_d^{\alpha_d-1}.$$

First Modelling Method VI

自然地，我们知道 Dirichlet 分布是多项分布的共轭先验分布，其后验分布的核为

$$\begin{aligned}\pi(\boldsymbol{\theta}|\mathbf{x}) &\propto \text{Multi}(\mathbf{x}; n, \theta_1, \dots, \theta_D) \cdot \text{Diri}(\boldsymbol{\theta}; \boldsymbol{\alpha}) \\ &\propto \prod_{i=1}^D \theta_i^{x_i + \alpha_i - 1} \sim \text{Diri}(\boldsymbol{\theta}|\boldsymbol{\alpha}'),\end{aligned}$$

其中 $\boldsymbol{\alpha}' = (\alpha_1 + x_1, \dots, \alpha_D + x_D)$.

First Modelling Method VII

对于后验分布的参数估计我们考虑最大后验估计 (Maximum a posteriori estimation, MAE), Dirichlet 分布核函数具有和多项分布的似然函数 (3) 相似的形式, 只需要把 x_d 换成 $\alpha_d - 1$, 因此通过多项分布最大似然估计可以得到 Dirichlet 分布的参数估计

$$\theta_d = \frac{\alpha_d - 1}{\sum_{d=1}^D \alpha_d - D}, d = 1, \dots, D.$$

则最大后验估计 MAE 即

$$\theta = \frac{\alpha' - 1}{\alpha'_0 - D}, \quad (6)$$

其中 $\alpha' = (\alpha_1 + x_1, \dots, \alpha_D + x_D)$, $\alpha'_0 = \sum_{d=1}^D (\alpha_d + x_d)$.

所有插补方法的核心问题是我们并没有完全观察到数据 x ，而只是观察到其中的一部分。在多项式情况下，假设我们已经将观察到的数据分为观察到的模式 x^{obs} 和缺失模式 x^{mis} 。用 $s = 1, 2, \dots, S$ 来索引缺失模式，并定义一组指示变量：

$$r_{sj} = \begin{cases} 1 & \text{如果分类变量 } Y_j \text{ 在模式 } s \text{ 中是观察到的} \\ 0 & \text{如果分类变量 } Y_j \text{ 在模式 } s \text{ 中是缺失的} \end{cases}$$

令 $O_s(y)$ 和 $M_s(y)$ 分别表示在每个缺失模式中的已观察变量集和缺失变量集，元素定义如下：

$$O_s(y) = \{y_j : r_{sj} = 1\}$$

$$M_s(y) = \{y_j : r_{sj} = 0\}$$

记观察到的完整的数据计数汇总到表格 x_y ¹ 中，而其余带缺失的观测数据是部分观察的，对每个缺失模式 s 的每个观测进行合并计数，结果为 $z_{O_s(y)}^{(s)}$ 。这一表格如下图所示：

¹关于 $x_d, x_y, \theta_d, \theta_y$ 的下标 d 和 y 实际上表达的是一个意思。只不过 d 是当我们把所有分类变量的因子水平展开成一行长度为 $D = \prod_j^p d_j$ 的表格时其中的一个单元格，而 y 可以看成是一个有 $D = \prod_j^p d_j$ 个数组的集合中的一个数组。

	age	gender	edu_attain	pov_status	ind_income	counts
358	under15	Male	NA	at_above_pov_level	10k_lt15k	7
360	18_24	Male	NA	at_above_pov_level	10k_lt15k	2
361	25_29	Male	NA	at_above_pov_level	10k_lt15k	5
362	30_34	Male	NA	at_above_pov_level	10k_lt15k	1
363	35_39	Male	NA	at_above_pov_level	10k_lt15k	3
364	40_44	Male	NA	at_above_pov_level	10k_lt15k	2
365	45_49	Male	NA	at_above_pov_level	10k_lt15k	2
366	50_54	Male	NA	at_above_pov_level	10k_lt15k	5
367	55_59	Male	NA	at_above_pov_level	10k_lt15k	3
369	65_69	Male	NA	at_above_pov_level	10k_lt15k	1
375	under15	Female	NA	at_above_pov_level	10k_lt15k	8
377	18_24	Female	NA	at_above_pov_level	10k_lt15k	4
378	25_29	Female	NA	at_above_pov_level	10k_lt15k	8
379	30_34	Female	NA	at_above_pov_level	10k_lt15k	1
380	35_39	Female	NA	at_above_pov_level	10k_lt15k	2
381	40_44	Female	NA	at_above_pov_level	10k_lt15k	4
382	45_49	Female	NA	at_above_pov_level	10k_lt15k	1
383	50_54	Female	NA	at_above_pov_level	10k_lt15k	2
385	60_64	Female	NA	at_above_pov_level	10k_lt15k	2

图: 当 s 取定一种缺失模式时, $z_{O_s(y)}^{(s)}$

考虑 $x_{O_s(y)}^{(s)} = \{x_y^{(s)} : M_s(y) \in M_s\}$ 是所有可能的完整数据集中对 $z_{O_s(y)}^{(s)}$ 作出贡献的单元格。如下表所示的最后一列

图: $x_{O_s(y)}^{(s)}$

Name	Type	Value
search_out	list [593]	List of length 593
[[1]]	integer [7]	1 33 65 97 129 161 ...
[[2]]	integer [7]	3 35 67 99 131 163 ...
[[3]]	integer [7]	4 36 68 100 132 164 ...
[[4]]	integer [7]	5 37 69 101 133 165 ...
[[5]]	integer [7]	6 38 70 102 134 166 ...
[[6]]	integer [7]	7 39 71 103 135 167 ...
[[7]]	integer [7]	8 40 72 104 136 168 ...
[[8]]	integer [7]	9 41 73 105 137 169 ...
[[9]]	integer [7]	10 42 74 106 138 170 ...
[[10]]	integer [7]	12 44 76 108 140 172 ...
[[11]]	integer [7]	17 49 81 113 145 177 ...
[[12]]	integer [7]	19 51 83 115 147 179 ...
[[13]]	integer [7]	20 52 84 116 148 180 ...
[[14]]	integer [7]	21 53 85 117 149 181 ...
[[15]]	integer [7]	22 54 86 118 150 182 ...
[[16]]	integer [7]	23 55 87 119 151 183 ...
[[17]]	integer [7]	24 56 88 120 152 184 ...

所有可能数据在此部分观察值表格中落入给定单元格的边际概率表示为：

$$\beta_{O_s(y)} = \sum_{M_s(y) \in M_s} \theta_y$$

部分观测数据对所有可能数据的对数似然函数贡献为：

$$l(\theta | Y_{\text{mis}}) = \sum_{s=1}^S \sum_{O_s(y) \in O_s} z_{O_s(y)} \log(\beta_{O_s(y)})$$

这种情景下 EM 算法是直接的，Fuchs(1982) 首次描述了多变量情况，对于 E-step 我们根据观测数据和当前的 θ 值来计算期望的汇总统计量：

$$\mathbb{E}(x_y|Y, \theta) = x_y + \sum_{s=1}^S z_{O_s(y)}^s \theta_y / \beta_{O_s(y)}.$$

而这就导出了 M-step. 根据前面提到的 Dirichlet 分布最大后验估计 (MAE) 就可以导出最大化后验概率：

$$\hat{\theta}_y = \frac{\mathbb{E}(x_y) + \alpha_y - 1}{n + \alpha_0 - D}.$$

Algorithm 1: 1 iteration of EM for saturated multinomial model

```
for  $y \in \mathcal{Y}$  do
  |  $\mathbb{E}(x_y) \leftarrow 0$ 
end
for  $s = 1$  to  $S$  do
  | for  $\mathcal{O}_s(y) \in \mathcal{O}_s$  do
    | if  $M_s = \emptyset$  then
    |   |  $x_y \leftarrow x_y + z_{\mathcal{O}_s(y)}^{(s)}$ ;
    | else
    |   |  $sum = 0$ ;
    |   | for  $\mathcal{M}_s(y) \in M_s$  do
    |   |   |  $sum \leftarrow sum + \theta_y; x_y \leftarrow x_y + z_{\mathcal{O}_s(y)}^{(s)} \theta_y / sum$ 
    |   | end
    |   end
    | end
  | end
end
end
for  $y \in \mathcal{Y}$  do
  |  $\theta_y \leftarrow (x_y + \alpha_y - 1) / (n + \alpha_0 - D)$ .
end
```



1. Introduction

2. Imputation for Missing Data Using EM

3. Multiply Imputation For Missing Data Using FRM & DA

Modelling and posterior computation

Posterior computation within a data augmentation algorithm

Data Augmentation

4. Rpackage

5. References



Miss data and multiple imputation I

假设我们有一个 $n \times p$ 的数据集 $X = (x_1, \dots, x_p)$, 其中 $x_j = (x_{1,j}, \dots, x_{n,j})', j = 1, \dots, p$ 看作数据集 X 的第 j 个变量。我们考虑缺失指标矩阵 $M = (m_1, \dots, m_p)$, 其中 $m_j = (m_{1,j}, \dots, m_{n,j})', m_{i,j} = 1$ 表示 $x_{i,j}$ 值缺失, $i = 1, \dots, n, j = 1, \dots, p$.

于是, 我们可以根据缺失指标矩阵对数据集 X 进行分类, 分为完整观察数据 $X_{\text{obs}} = \{x_{i,j} : m_{i,j} = 0\}$ 和缺失数据 $X_{\text{mis}} = \{x_{i,j} : m_{i,j} = 1\}$. 在多重插补中, 缺失数据的值通过它们的后验预测分布 $p(X_{\text{mis}} | X_{\text{obs}})$ 来进行插补, 一般进行 m 次插补产生 m 个完整的数据集 $X_{\text{com}}^{(1)}, \dots, X_{\text{com}}^{(m)}$.

Miss data and multiple imputation II

多重插补方法一个关键问题是从合理的分布中抽取插补值，然而大多数情况下确定 $p(\mathbf{X}_{\text{mis}}|\mathbf{X}_{\text{obs}})$ 的解析表达式是不可能的。实际的想法是对 $p(\mathbf{X}|\Theta)$ 建模，其中 Θ 代表模型中的一组未知的参数，使用这个模型和一个合适的先验分布 $P(\Theta)$ ，可以在每次迭代 t 中通过利用 MCMC 方法从 $p(\mathbf{X}_{\text{mis}}|\Theta^{(t)}, \mathbf{X}_{\text{obs}})$ (来生成完整数据集 $\mathbf{X}_{\text{com}}^{(t)}$) 和 $p(\Theta|\mathbf{X}_{\text{mis}}^{(t)}, \mathbf{X}_{\text{obs}})$ 中迭代地抽取样本来实现从 $p(\mathbf{X}_{\text{mis}}|\mathbf{X}_{\text{obs}})$ 中抽取样本。一旦样本 $(\mathbf{X}_{\text{mis}}^{(t)}, \Theta^{(t)})$ 收敛到它们的平稳分布，就可以认为这些样本来自于联合分布 $p(\mathbf{X}_{\text{mis}}, \Theta|\mathbf{X}_{\text{obs}})$ 。

这种方式插补缺失值就被称为是数据增强 (Data Augmentation) 方法。下面将介绍一种建模策略，通过数据增强在分类变量的数据集中插补缺失值。

1. Introduction

2. Imputation for Missing Data Using EM

3. Multiply Imputation For Missing Data Using FRM & DA

Modelling and posterior computation

Posterior computation within a data augmentation algorithm

Data Augmentation

4. Rpackage

5. References



Modelling

本节中我们将提出一种特别的建模策略，允许通过 MCMC 方法从其后验预测分布中进行插补。

我们通过一系列条件回归模型来建模联合分布 $p(\mathbf{X}|\Theta)$:

$$\begin{aligned} p(\mathbf{X}|\Theta) &= p(\mathbf{x}_1|\theta^{(1)}) \prod_{k=2}^p p(\mathbf{x}_k|\mathbf{x}_1, \dots, \mathbf{x}_{k-1}, \theta^{(k)}) \\ &= \prod_{i=1}^n \left\{ p(x_{i,1}|\theta^{(1)}) \prod_{k=2}^p p(x_{i,k}|x_{i,1}, \dots, x_{i,k-1}, \theta^{(k)}) \right\}. \end{aligned} \quad (7)$$

其中 $\theta^{(k)}$ 代表回归模型中第 k 个变量的参数向量， $\Theta = \{\theta^{(k)}, k = 1, \dots, p\}$. 这种使用联合分布的因式分解来进行缺失值插补的建模策略就被称为**因式回归模型**(Factored Regression Model, FRM)².

²在此假设所有变量都有缺失值，如果某些变量是完全观测的，建模框架将保持不变，且我们将在每个回归模型中对这些完全观测的变量进行条件化处理。

1. Introduction

2. Imputation for Missing Data Using EM

3. Multiply Imputation For Missing Data Using FRM & DA

Modelling and posterior computation

Posterior computation within a data augmentation algorithm

Data Augmentation

4. Rpackage

5. References



Posterior Computation I

为了保留数据集中的关系，一种简化的方法是通过广义线性模型来建模数据集的联合分布。每个模型 $p(\mathbf{x}_k | \mathbf{x}_1, \dots, \mathbf{x}_{k-1}, \theta^{(k)})$ 指定一个形式，该形式取决于变量 $\mathbf{x}_k$ 的变量类型。对于本文考虑的分类变量，我们采用多项式逻辑回归模型。

我们假设 $\mathbf{x}_1, \dots, \mathbf{x}_p$ 是分类变量，且对于每个 $\mathbf{x}_k$, $k = 1, \dots, p$ 可能的取值为 $1, \dots, L_k$ 。下面提供 $k = 1, \dots, p$ 的表达式。当 $k = 1$ 时， $\mathbf{x}_1$ 用标准的多项分布进行建模，特别地，

$$p(x_{i,1} | \theta^{(1)}) \propto \text{Multi}(\pi_1^{(1)}, \dots, \pi_{L_1}^{(1)}),$$

其中 $\pi_{j^{(1)}}^{(1)} = p(x_{i,1} = j^{(1)} | \theta^{(1)}), j^{(1)} = 1, \dots, L_1$ 。我们给 $\pi^{(1)}$ 一个 Dirichlet 先验分布

$$p(\pi^{(1)}) = \text{Diri}(\alpha_1, \dots, \alpha_{L_1})$$

Posterior Computation II

我们采用非信息先验置 $\alpha_{j(1)} = 0.5$. 对于 $k = 2, \dots, p$, 采用多项式 logistic 回归模型, 特别地,

$$p(x_{i,k} | x_{i,1}, \dots, x_{i,k-1}, \theta^{(k)}) \propto \text{Multi}(\pi_{i,1}^{(k)}, \dots, \pi_{i,L_k}^{(k)}),$$

其中

$$\begin{aligned} \pi_{i,j^{(k)}}^{(k)} &:= p(x_{i,k} | x_{i,1}, \dots, x_{i,k-1}, \theta^{(k)}) \\ &= \frac{\exp \left(\beta_{0,j^{(k)}}^{(k)} + \sum_{b=1}^{k-1} \sum_{j^{(b)}=2}^{L_b} \beta_{b,j^{(k)}}^{(k),j^{(b)}} I(x_{i,b} = j^{(b)}) \right)}{\sum_{u=1}^{L_k} \exp \left(\beta_{0,u}^{(k)} + \sum_{b=1}^{k-1} \sum_{j^{(b)}=2}^{L_b} \beta_{b,u}^{(k),j^{(b)}} I(x_{i,b} = j^{(b)}) \right)}, \end{aligned}$$

其中 $j^{(k)} = 1, \dots, L_k$, 令 $\theta^{(k)} = (\theta_1^{(k)}, \dots, \theta_{L_k}^{(k)})$, 且

$$\theta_{j^{(k)}}^{(k)} = (\beta_{0,j^{(k)}}^{(k)}, \beta_{1,j^{(k)}}^{(k),2}, \dots, \beta_{1,j^{(k)}}^{(k),L_1}, \dots, \beta_{k-1,j^{(k)}}^{(k),2}, \dots, \beta_{k-1,j^{(k)}}^{(k),L_{k-1}}).$$

Posterior Computation III

为了标定 (identifiability) 模型, 我们设置 $\theta_1^{(k)} = \mathbf{0}$, 其余的 $\theta_{j^{(k)}}^{(k)}$ 设置先验为

$$p(\theta_{j^{(k)}}^{(k)}) = \text{MVN}(\mathbf{0}, \Sigma),$$

对于 $j^{(k)} = 2, \dots, L_k$ 且 Σ 是对角元素比较大的对角矩阵。

1. Introduction

2. Imputation for Missing Data Using EM

3. Multiply Imputation For Missing Data Using FRM & DA

Modelling and posterior computation

Posterior computation within a data augmentation algorithm

Data Augmentation

4. Rpackage

5. References



l-step l

在插补步骤中，在参数值作为条件时，首先根据以下完整条件离散分布插补缺失的分类变量

$$\begin{aligned}\tilde{\pi}_{i,j^{(k)}}^{(k)} &:= p(x_{i,k}^* = j^{(k)} | x_{i,1}^* = j^{(1)}, \dots, x_{i,k-1}^* = j^{(k-1)}, x_{i,k+1}^* = j^{(k+1)}, \dots, x_{i,p}^* = j^{(p)}, \Theta) \\ &\propto p(x_{i,k}^* = j^{(k)} | x_{i,1}^* = j^{(1)}, \dots, x_{i,k-1}^* = j^{(k-1)}, \Theta) p(x_{i,k+1}^* = j^{(k+1)} | x_{i,1}^* = j^{(1)}, \dots, x_{i,k}^* = j^{(k)}, \Theta) \\ &\quad \times \dots \times p(x_{i,p}^* = j^{(p)} | x_{i,1}^* = j^{(1)}, \dots, x_{i,p-1}^* = j^{(p-1)}, \Theta),\end{aligned}$$

其中 $j^{(k)} \in \{1, \dots, L_k\}$. 上述未归一化的表达式说明了如何利用 Bayes 公式推导出概率 $\tilde{\pi}_{i,j^{(k)}}^{(k)}$.

I-step II

进而推导出归一化的概率 $\tilde{\pi}_{i,j^{(k)}}^{(k)}$,

$$\tilde{\pi}_{i,j^{(k)}}^{(k)} = \frac{\prod_{b=k}^p \pi_{i,j^{(b)}}^{(b)}}{\sum_{u=1}^{L_k} \left\{ \pi_{i,u}^{(k)} \prod_{b=k+1}^p \pi_{i,j^{(b)}}^{(b)} \right\}},$$

其中 $\pi_{i,j^{(b)}}^{(b)} = p(x_{i,b}^* = j^{(b)} | x_{i,1}^*, \dots, x_{i,b-1}^*, \theta^{(b)})$ 是可以从多项回归模型中取得的概率。
我们可以将第 t 次迭代中分类变量缺失值插补为 $x_{i,k}^{(t)}$, 插补后的完整数据集为 $\mathbf{X}_{\text{com}}^{(t)}$.

P-step I

在 P-step 中, 条件于插补后的数据集, 首先从 Dirichlet 分布 $\text{Diri}(\alpha)$ 中采样 $\theta^{(1)}$ 的值, 其中 α 的值为

$$\alpha = \left(\alpha_1 + \sum_{i=1}^n I(x_{i,1} = 1), \alpha_2 + \sum_{i=1}^n I(x_{i,1} = 2), \dots, \alpha_{L_1} + \sum_{i=1}^n I(x_{i,1} = L_1) \right)'.$$

接下来, 对于 $k = 2, \dots, p$, 使用 Metropolis-Hastings 步骤提出 $\theta^{(k)} = (\theta_1^{(k)}, \dots, \theta_{L_k}^{(k)})$ 的值, 其中 $\theta_{j^{(k)}}^{(k)} = (\beta_{0,j^{(k)}}^{(k)}, \beta_{1,j^{(k)}}^{(k),2}, \dots, \beta_{1,j^{(k)}}^{(k),L_1}, \dots, \beta_{k-1,j^{(k)}}^{(k),2}, \dots, \beta_{k-1,j^{(k)}}^{(k),L_{k-1}})$, $j^{(k)} = 1, \dots, L_k$. 为了标定模型, 我们置 $\theta_1^{(k)} = 0$.

P-step II

我们考虑基于每次迭代 t 中插补数据的对数似然函数 $l(\theta^{(k)}; \mathbf{X}_{\text{com}}^{(t)})$ 独立的提议分布，对数似然函数可以表示为

$$l(\theta^{(k)}; \mathbf{X}_{\text{com}}^{(t)}) = \sum_{w=1}^{L_k} \sum_{i=1}^n \ln \left(\frac{\exp \left(\beta_{0,w}^{(k)} + \sum_{b=1}^{k-1} \sum_{j^{(b)}=2}^{L_b} \beta_{b,w}^{(k),j^{(b)}} f(x_{i,b}^{(t)}, x_{i,b}, m_{i,b}) \right)}{\sum_{u=1}^{L_k} \exp \left(\beta_{0,u}^{(k)} + \sum_{b=1}^{k-1} \sum_{j^{(b)}=2}^{L_b} \beta_{b,u}^{(k),j^{(b)}} f(x_{i,b}^{(t)}, x_{i,b}, m_{i,b}) \right)} \right)^{I(x_{i,k}=w)},$$

其中 $f(x_{i,b}^{(t)}, x_{i,b}, m_{i,b}) = (I(x_{i,b}^{(t)} = j^{(b)})m_{i,b} + I(x_{i,b} = j^{(b)})(1 - m_{i,b}))$. 我们从正态分布

P-step III

$N(\mu^{(t)}, \Sigma^{(t)})$ 中生成 $\theta^{(k)}$ 的提议分布 (proposals), 其中 $\mu^{(t)}$ 是最大化 $l(\theta^{(k)}; \mathbf{X}_{\text{com}}^{(t)})$ 的值, 而 $\Sigma^{(t)}$ 由以下公式给出:


$$\Sigma^{(t)} = -\mathbb{E} \left[\frac{\partial^2}{\partial \beta_{j,w}^{(k)} \partial \beta_{j,\tilde{w}}^{(k)}} l(\theta^{(k)}; \mathbf{X}_{\text{com}}^{(t)}) \right]_{\theta^{(k)} = \mu^{(t)}}^{-1}.$$

因此, 对于只包含分类变量的数据集, 我们提出了一种建模策略, 允许从其联合后验分布中采样所有未知量, 从而通过从后验预测分布 $p(\mathbf{X}_{\text{mis}} | \mathbf{X}_{\text{obs}})$ 中采样来创建插补数据集。

1. Introduction
2. Imputation for Missing Data Using EM
3. Multiply Imputation For Missing Data Using FRM & DA
4. Rpackage
 - Results
 - R 包对比
5. References



Merge and Match using Rcpp



1. Introduction
2. Imputation for Missing Data Using EM
3. Multiply Imputation For Missing Data Using FRM & DA
4. Rpackage
Results
R 包对比
5. References



tract2221 数据集包含 3974 名来自美国加利福尼亚州洛杉矶县第 2221 普查区的个体，来源于截至 2014 年的 5 年美国社区调查。数据集包含 10 个分类变量，本次插补选取了 5 个变量，使用本包函数 impute4mmv，方法为 EM 法，插补结果如下所示：

	age	gender	edu_attain	pov_status	ind_income
1	25_29	Female	NA	at_above_pov_level	10k_lt15k
2	35_39	Male	lt_hs	at_above_pov_level	10k_lt15k
3	30_34	Male	ba_deg	at_above_pov_level	15k_lt25k
4	40_44	Female	ba_deg	NA	10k_lt15k
5	45_49	Male	lt_hs	at_above_pov_level	50k_lt65k
6	60_64	Female	assoc_dec	at_above_pov_level	25k_lt35k
7	under15	Male	lt_hs	at_above_pov_level	35k_lt50k
8	25_29	Male	ba_deg	at_above_pov_level	10k_lt15k
9	65_69	Female	hs_grad	NA	50k_lt65k
10	65_69	Male	lt_hs	NA	50k_lt65k
11	65_69	Male	lt_hs	at_above_pov_level	10k_lt15k
12	18_24	Female	hs_grad	at_above_pov_level	35k_lt50k
13	under15	Male	lt_hs	at_above_pov_level	15k_lt25k
14	30_34	Male	hs_grad	at_above_pov_level	15k_lt25k
15	75_79	Female	lt_hs	at_above_pov_level	35k_lt50k
16	40_44	Female	some_hs	at_above_pov_level	gt75k
17	45_49	Female	some_hs	at_above_pov_level	10k_lt15k

	age	gender	edu_attain	pov_status	ind_income
1	25_29	Female	some_col	at_above_pov_level	10k_lt15k
2	35_39	Male	lt_hs	at_above_pov_level	10k_lt15k
3	30_34	Male	ba_deg	at_above_pov_level	15k_lt25k
4	40_44	Female	ba_deg	at_above_pov_level	10k_lt15k
5	45_49	Male	lt_hs	at_above_pov_level	50k_lt65k
6	60_64	Female	assoc_dec	at_above_pov_level	25k_lt35k
7	under15	Male	lt_hs	at_above_pov_level	35k_lt50k
8	25_29	Male	ba_deg	at_above_pov_level	10k_lt15k
9	65_69	Female	hs_grad	at_above_pov_level	50k_lt65k
10	65_69	Male	lt_hs	at_above_pov_level	50k_lt65k
11	65_69	Male	lt_hs	at_above_pov_level	10k_lt15k
12	18_24	Female	hs_grad	at_above_pov_level	35k_lt50k
13	under15	Male	lt_hs	at_above_pov_level	15k_lt25k
14	30_34	Male	hs_grad	at_above_pov_level	15k_lt25k
15	75_79	Female	lt_hs	at_above_pov_level	35k_lt50k
16	40_44	Female	some_hs	at_above_pov_level	gt75k
17	45_49	Female	some_hs	at_above_pov_level	10k_lt15k

1. Introduction
2. Imputation for Missing Data Using EM
3. Multiply Imputation For Missing Data Using FRM & DA
4. Rpackage
Results
R 包对比
5. References



算法速度比较

为了测试算法速度，选用 `microbenchmark` 包对现存多种常见插补方法以及 `imputeMulti` 包与本包 EM 法比较，数据集为 `tract2221[,1:5]` 共五个变量，结果如下表所示：

expr	min	lq	mean	median	uq	max	neval
MC-EM	9479.354	9618.06	10042.36	9901.17	10338.69	11003.08	10
IM-EM	38549.68	38952.25	39951.13	39539.54	40934.36	41902.42	10
amelia	188.936	195.77	204.94	204.28	205.90	226.48	10
mice	16382.20	16416.34	16736.28	16486.73	16990.03	17916.52	10

所有算法都在几毫秒或几秒钟内完成。Amelia 是最快的算法，在这次测试中超过了我们的插补方法一个数量级。但我们的方法略快于 `mice` 以及明显快于 `imputeMulti` 包

准确性比较

- 对观察级插补的准确性进行测试。
- 从 `tract2221[,c(1,2,4,7,9)]` 中提取完整案例并随机插入缺失值。然后对这些数据集进行观察级插补，并将插补与插入缺失前的数据集进行比较。
- 为了测试对数据中缺失量的敏感性，使用 5%、10% 和 15% 的缺失率运行测试。对每个插入缺失值水平运行 20 次这样的测试，平均结果如表 1 所示。

缺失率	MC-EM	IM-EM	Amelia	mice
5%	0.3112	0.3071	0.3527	0.4495
10%	0.3188	0.3188	0.3658	0.4530
15%	0.3290	0.3272	0.3567	0.4456

表: 单一插补下 MissCat、ImputeMulti、Amelia 和 mice 的平均准确度。

- 随着缺失值的增加，每种方法的插补准确率都相对稳定
- Miss Cat 在完全匹配真实观测值方面比 ImputeMulti 准确率高
- 相比成熟的包，Miss Cat 存在改进空间。

1. Introduction
2. Imputation for Missing Data Using EM
3. Multiply Imputation For Missing Data Using FIRM & DA
4. Rpackage
5. References



References



J.L.Schafer (1997)

Analysis of Incomplete Multivariate Data (1st ed.) models

Chapman and Hall/CRC. <https://doi.org/10.1201/9780367803025>



Min Cherng Lee, Robin Mitra (2016)

Multiply imputing missing values in data sets with mixed measurement scales using a sequence of generalised linear models

Computational Statistics and Data Analysis 95(2016), 24 – 38.

The End

